

# 03\_phase2\_climat\_25

May 15, 2026

## 1 Phase 2 — Lien climat–CO2 à l'échelle globale ( $2.5^\circ \times 2.5^\circ$ )

### Projet Climat & CO2 — Migration R → Python

Ce notebook synthétise les phases **2 à 4** : caractérisation statistique de 18 variables climatiques (+ 3 Cloud Radiative Effects) issues des réanalyses **NCAR CFSR/CFSv2**, et étude de leur lien avec le CO2 NOAA. La résolution  $2.5^\circ$  donne  $144 \times 73 = 10\,512$  pixels, moyennés par  $\cos(\text{latitude})$  pour produire **une série mensuelle globale par variable**.

Pipeline complet : `scripts/phase2_climat_25/02_global_means.py` → `13_phase3_homog_comparison.py`.

### 1.1 1. Question scientifique

**Les variations interannuelles du climat sont-elles liées au CO2 au-delà de la tendance commune, et dans quel sens (climat → CO2 ou CO2 → climat) ?**

Trois questions méthodologiques sous-jacentes : \* Comment **séparer** le signal de tendance commune (séculaire) du signal interannuel propre ? \* Quelles variables sont **corrélées spuriously** (uniquement par la trend) vs réellement liées au CO2 ? \* La transition modèle **CFSR → CFSv2 (jan 2011)** introduit-elle des artefacts systématiques dans les conclusions ?

### 1.2 2. Données utilisées

| Variable                       | Famille                | Niveau                |
|--------------------------------|------------------------|-----------------------|
| T2m, T500                      | Thermo                 | 2 m, 500 hPa          |
| SPFH2m, PWAT, APCP             | Hydro                  | 2 m, colonne, surface |
| TCDC                           | Nuages                 | colonne               |
| DLWRF, ULWRF, DSWRF, USWRF     | Flux radiatifs all-sky | surface               |
| CSDLF, CSULF, CSDSF, CSUSF     | Flux clear-sky         | surface               |
| PRMSL, CDUVB, DUVB, ALBDO      | Autres                 | divers                |
| <b>CRE_SW, CRE_LW, CRE_net</b> | Dérivés                | (all-sky — clear-sky) |

**Source** : 564 fichiers NetCDF mensuels 1979-01 → 2025-12, résolution  $2.5^\circ \times 2.5^\circ$ .

```
[1]: import sys
from pathlib import Path
sys.path.insert(0, str(Path.cwd().parent))
```

```

import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

from climat import config
from climat.plots import setup_theme
setup_theme()

OUT = config.OUT_PHASE2
clim = pd.read_csv(OUT / 'climate_co2_monthly.csv', parse_dates=['date'])
trends = pd.read_csv(OUT / 'trends_summary.csv')
synth = pd.read_csv(OUT / 'synthese_finale.csv')
granger = pd.read_csv(OUT / 'granger_results.csv')
jumps = pd.read_csv(OUT / 'cfsr_to_cfsv2_jumps.csv')
cmp_homog = pd.read_csv(OUT / 'comparison_homog_correlations.csv')

print(f"climate_co2_monthly : {clim.shape}")
print(f"trends_summary      : {trends.shape}")
print(f"synthese_finale       : {synth.shape}")

```

```

climate_co2_monthly : (564, 26)
trends_summary      : (21, 10)
synthese_finale     : (21, 11)

```

### 1.3 3. Méthodes principales

5 représentations temporelles systématiquement comparées :

| Représentation | Calcul                    | Capture                         |
|----------------|---------------------------|---------------------------------|
| level          | brut                      | trend séculaire dominante       |
| anom           | level – climato mensuelle | trend conservée, saison retirée |
| resid          | anom – fit linéaire(t)    | <b>signal interannuel pur</b>   |
| d1             | $X_t - X_{t-1}$           | saisonnalité forte              |
| d12            | $X_t - X_{t-12}$          | taux annuel de croissance       |

Tests statistiques : \* Mann-Kendall + Sen + bootstrap (R=500) sur chaque variable. \* OLS multivarié + sélection stepwise AIC backward. \* LassoCV (10 plis) pour régularisation. \* Granger (lag 6 mois) sur les résidus et le d12. \* Homogénéisation : modèle additif  $y = a + b \cdot t + c \cdot \mathbb{1}_{t \geq 2011} + \text{season}(t)$ .

### 1.4 4. Résultats — Tendances 47 ans (Sen + bootstrap)

16 variables sur 21 ont une **tendance significative** (Mann-Kendall  $p < 0.05$ ) :

```

[2]: trends_sig = trends.copy()
trends_sig['significant'] = trends_sig['mk_pvalue'] < 0.05

```

```

trends_sig['pct_per_year'] = trends_sig['sen_per_year'] / trends_sig['mean'] * 100
trends_sig = trends_sig.sort_values('pct_per_year')
print(f"Tendances significatives : {int(trends_sig['significant'].sum())} / {len(trends_sig)}")
print(f"\nTop 5 plus rapides en %/an :")
print(trends_sig.assign(abs_pct=trends_sig['pct_per_year'].abs())
      .sort_values('abs_pct', ascending=False)
      .head(5)[['var', 'sen_per_year', 'pct_per_year', 'mk_pvalue']].round(4).
      to_string(index=False))


fig, ax = plt.subplots(figsize=(10, 8))
colors = ['tomato' if v > 0 else 'steelblue' for v in trends_sig['pct_per_year']]
ax.barh(trends_sig['var'], trends_sig['pct_per_year'], color=colors)
for i, v in enumerate(trends_sig['pct_per_year']):
    ax.text(v, i, f' {v:+.3f}',
            ha='left' if v > 0 else 'right', va='center', fontsize=8)
ax.axvline(0, color='black', lw=0.4)
ax.set_xlabel('% par an')
ax.set_title('Vitesse d\'évolution normalisée 1979-2025 (Sen × 100 / moyenne)')
fig.tight_layout()

```

Tendances significatives : 16 / 21

Top 5 plus rapides en %/an :

| var    | sen_per_year | pct_per_year | mk_pvalue |
|--------|--------------|--------------|-----------|
| PWAT   | 0.0522       | 0.2115       | 0.0       |
| TCDC   | 0.1173       | 0.1939       | 0.0       |
| CRE_LW | -0.0481      | -0.1897      | 0.0       |
| CRE_SW | 0.0761       | -0.1687      | 0.0       |
| APCP   | 0.0008       | 0.1471       | 0.0       |



**Conclusions §4 :** \* **T2m global +0.78 K** sur 47 ans (Sen 0.0167 K/an). \* **CSDLF +7.84 W/m<sup>2</sup>** sur 47 ans : signature directe du **forçage GES** (effet de serre LW ciel clair). \* **PWAT +0.21 %/an** : humidification globale conforme à Clausius-Clapeyron (~7%/K). \* **TCDC +0.19 %/an** (avec saut algorithmique CFSR/CFSv2). \* **CRE\_LW -0.19 %/an, CRE\_SW -0.17 %/an** : perte d'effet refroidissant des nuages SW + perte d'effet réchauffant LW.

## 1.5 5. Corrélations climat-CO2 — le piège des tendances communes

**Cas d'école :** sur les **niveaux bruts**, beaucoup de variables ont une corrélation très forte avec le CO2 ( $r > 0.5$ ) simplement parce qu'elles partagent une tendance commune. Le détendrement révèle un signal **beaucoup plus modeste**.


```
[3]: # Heatmap des 5 représentations
synth_plot = synth.set_index('var')[['r_level', 'r_anom', 'r_resid', 'r_d1', 'r_d12']]
synth_plot.columns = ['Niveaux', 'Anomalies', 'Résidus', 'd1', 'd12']
synth_plot = synth_plot.sort_values('Résidus', key=lambda c: c.abs(), ascending=False)

fig, ax = plt.subplots(figsize=(7, 9))
```

```

sns.heatmap(synth_plot, annot=True, fmt='.2f', cmap='RdBu_r',
            center=0, vmin=-1, vmax=1, ax=ax,
            cbar_kws={'label': 'corr lation Pearson'})
ax.set_title('Corr lation chaque variable CO2 selon la repr sentation\n'
            '(tri es par |r_r siduals| d croissant)')
fig.tight_layout()

```



```
[4]: # Combien de variables "spurious" ?
n_spurious = int((synth['spurious_trend'] == 'OUI').sum())
print(f"Variables \"spurious\" (|r_anom| > 0.5 mais |r_resid| < 0.25) : ␣
      ↳{n_spurious}/{len(synth)}")

print("\nTop 5 corrélations sur résidus (signal interannuel pur) :")
print(synth.head(5)[['var', 'r_resid', 'sens_d12']].round(3).
      ↳to_string(index=False))
```

Variables "spurious" (|r\_anom| > 0.5 mais |r\_resid| < 0.25) : 10/21

Top 5 corrélations sur résidus (signal interannuel pur) :

|  | var     | r_resid | sens_d12 |
|--|---------|---------|----------|
|  | CRE_LW  | -0.523  | X -> CO2 |
|  | CRE_SW  | 0.489   | aucun    |
|  | DSWRF   | 0.437   | aucun    |
|  | CRE_net | 0.432   | CO2 -> X |
|  | PRMSL   | -0.394  | X -> CO2 |

**Conclusions §5 :** \* **10 variables sur 21** sont *spurious* : forte corrélation sur niveaux, presque nulle sur résidus. \* À l'échelle interannuelle, seules **5 variables** ont  $|r| > 0.3$  sur résidus : CRE\_LW (−0.52), CRE\_SW (+0.49), DSWRF (+0.44), CRE\_net (+0.43), PRMSL (−0.39). \* Les **CRE** sont les variables qui réagissent le plus à l'ENSO (modulation des nuages tropicaux), ce qui explique leur forte corrélation interannuelle avec le CO2 (lui-même ENSO-sensible).

## 1.6 6. Causalité de Granger climat → CO2

**Test :** la connaissance des **6 derniers mois** d'une variable climatique X aide-t-elle à prédire le CO2 mieux que la connaissance des 6 derniers mois du CO2 seul ?

On teste sur la représentation **d12** (taux annuel) qui est stationnaire.

```
[5]: gr_d12 = granger.query("repr == 'd12']").sort_values('p_x_to_co2')
n_x_to_co2 = int(((gr_d12['p_x_to_co2'] < 0.05)).sum())
n_co2_to_x = int(((gr_d12['p_co2_to_x'] < 0.05)).sum())
print(f"Sur d12 (lag 6 mois) :")
print(f" Variables X → CO2 (p<0.05) : {n_x_to_co2}/21")
print(f" Variables CO2 → X (p<0.05) : {n_co2_to_x}/21")
print(f" → sens dominant : climat → CO2 ({n_x_to_co2/n_co2_to_x:.1f}× plus)")

fig, ax = plt.subplots(figsize=(10, 7))
df_plot = gr_d12.copy()
df_plot['nlogp_x_to_co2'] = -np.log10(df_plot['p_x_to_co2'].clip(lower=1e-300))
df_plot['nlogp_co2_to_x'] = -np.log10(df_plot['p_co2_to_x'].clip(lower=1e-300))
order = df_plot.sort_values('nlogp_x_to_co2')['var'].tolist()
y_pos = np.arange(len(order))
```


```

w = 0.4
for i, v in enumerate(order):
    row = df_plot[df_plot['var'] == v].iloc[0]
    ax.barh(i - w/2, row['nlogp_x_to_co2'], height=w, color='tomato',
            label='X → CO2' if i == 0 else None)
    ax.barh(i + w/2, row['nlogp_co2_to_x'], height=w, color='steelblue',
            label='CO2 → X' if i == 0 else None)
ax.axvline(-np.log10(0.05), ls='--', color='black', lw=0.7)
ax.set_yticks(y_pos); ax.set_yticklabels(order)
ax.set_xlabel('-log10(p)')
ax.set_title(f'Granger causality (d12, lag 6 mois) - {n_x_to_co2}/21 X→CO2 vs_
↳ {n_co2_to_x}/21 CO2→X')
ax.legend()
fig.tight_layout()

```

Sur d12 (lag 6 mois) :

- Variables X → CO2 (p<0.05) : 15/21
- Variables CO2 → X (p<0.05) : 8/21
- sens dominant : climat → CO2 (1.9× plus)



**Conclusions §6 :** \* À l'échelle **interannuelle**, le climat **précède** le CO2 de 6 mois pour 15 variables sur 21 → **carbon cycle response** : ENSO chauffe → stress hydrique forêts → respiration > photosynthèse → CO2 atmosphérique augmente. \* Le sens inverse (CO2 → climat, par exemple

via effet de serre direct) n'est significatif que sur 8 variables et **avec un délai > 6 mois** (effet plus lent). \* Ces résultats sont **cohérents** avec la phase 1 (ENSO lag 6 mois sur le taux annuel CO2).

## 1.7 7. Régression multivariée — $R^2 = 0.748$ sur 12 prédicteurs

OLS multivariée sur les résidus, suivie de sélection **stepwise AIC backward** :

```
[6]: # Re-fait la régression rapidement (mais on a déjà les conclusions dans ↵
      ↵ regression_summary.txt)
import pickle
import statsmodels.api as sm
from scipy.linalg import qr

with open(OUT / 'series_transformed.pkl', 'rb') as fh:
    ds = pickle.load(fh)

clim_vars = config.CLIM_VARS + ['CRE_SW', 'CRE_LW', 'CRE_net']
X = ds['resid'][clim_vars]
y = ds['resid']['co2_trend'].to_numpy()

# Retire les colonnes redondantes (mimique R lm())
Q, R, piv = qr(X.to_numpy(dtype=float), mode='economic', pivoting=True)
diag = np.abs(np.diag(R))
rank = int(np.sum(diag > 1e-9 * diag.max()))
aliased = [X.columns[i] for i in piv[rank:]]
X_clean = X.drop(columns=aliased)

fit_full = sm.OLS(y, sm.add_constant(X_clean)).fit()
print(f"Colonnes aliasées retirées : {aliased}")
print(f"R² complet : {fit_full.rsquared:.3f} | {X_clean.shape[1]} ↵
      ↵ prédicteurs")
print(f"Adj. R² : {fit_full.rsquared_adj:.3f}")
```


Colonnes aliasées retirées : ['ULWRF', 'USWRF', 'CRE\_LW']

R² complet : 0.750 | 18 prédicteurs

Adj. R² : 0.741

```
[7]: # Plot observé vs prédit
fitted = fit_full.fittedvalues
fig, ax = plt.subplots(figsize=(11, 5))
ax.plot(ds['resid']['date'], y, color='steelblue', lw=0.6, label='Observé')
ax.plot(ds['resid']['date'], fitted, color='tomato', lw=0.6, label='Prédit ↵
      ↵ (régression)')
ax.axhline(0, ls=':', color='grey', lw=0.5)
ax.set_ylabel('Résidu CO2 (ppm)')
ax.set_title(f'Régression CO2 résiduel ~ climat - R² = {fit_full.rsquared:.3f}')
ax.legend()
fig.tight_layout()
```





## 1.8 8. Saut CFSR → CFSv2 (jan 2011) — biais méthodologique

Le changement de réanalyse en jan 2011 (CFSR → CFSv2) introduit un **saut de niveau** dans 17 variables sur 21. Quantification par un modèle  $y = a + b \cdot t + c \cdot \mathbb{1}_{t \geq 2011} + \text{season}$ .

```
[8]: j = jumps.copy().sort_values('jump_in_sd', key=lambda s: s.abs(),
    ↪ascending=False)
print("Top 5 plus gros sauts (en écart-type de la variable) :")
print(j[['var', 'jump_pct', 'jump_in_sd', 'p_value', 'significant']]
    .head(5).round(3).to_string(index=False))
n_sig = int(j['significant'].sum())
print(f"\nVariables avec saut significatif (p<0.05) : {n_sig} / {len(j)}")


fig, ax = plt.subplots(figsize=(10, 7))
j_sorted = jumps.sort_values('jump_in_sd')
colors = ['tomato' if s else 'grey' for s in j_sorted['significant']]
ax.barh(j_sorted['var'], j_sorted['jump_in_sd'], color=colors)
for i, v in enumerate(j_sorted['jump_in_sd']):
    ax.text(v, i, f' {v:+.2f}', ha='left' if v > 0 else 'right', va='center',
    ↪fontSize=8)
ax.axvline(0, color='black', lw=0.4)
ax.set_xlabel('Saut / écart-type')
ax.set_title('Saut CFSR → CFSv2 (jan 2011) en écarts-type')
fig.tight_layout()
```

Top 5 plus gros sauts (en écart-type de la variable) :

| var    | jump_pct | jump_in_sd | p_value | significant |
|--------|----------|------------|---------|-------------|
| CRE_LW | -8.022   | -1.922     | 0.0     | True        |
| PRMSL  | -0.026   | -1.772     | 0.0     | True        |
| CRE_SW | -11.389  | 1.564      | 0.0     | True        |
| TCDC   | 4.347    | 1.140      | 0.0     | True        |

CRE\_net    -15.720            1.126            0.0            True

Variables avec saut significatif ( $p < 0.05$ ) : 17 / 21



```
[9]: # Impact sur les corrélations
print("=== Variables où le saut CFSR/CFSv2 modifie LE PLUS la corrélation au_
     ↪ CO2 ===")
print(cmp_homog.head(10).round(3).to_string(index=False))
```

```
=== Variables où le saut CFSR/CFSv2 modifie LE PLUS la corrélation au CO2 ===
   var  brute  homog  diff
CRE_SW  0.489  0.046 -0.443
CRE_LW -0.523 -0.094  0.429
DSWRF   0.437  0.012 -0.425
CRE_net  0.432  0.014 -0.418
DUVB    0.218 -0.148 -0.366
PRMSL  -0.394 -0.043  0.351
TCDC    0.080 -0.267 -0.347
DLWRF  -0.056  0.251  0.307
USWRF   0.130 -0.055 -0.185
T2m     0.233  0.352  0.119
```

**Conclusions §8 :** \* L'homogénéisation **détruit** beaucoup de corrélations apparentes (CRE\_SW,

CRE\_LW, DSWRF, CRE\_net, DUVB) — c’était surtout le saut technique qui les portait. \* L’homogénéisation **renforce** par contre la corrélation de **T2m**, **CSDLF**, **ULWRF** → ces variables portent un **signal climatique réel** masqué par le saut. \*  $R^2$  du modèle multivarié passe de **0.75** → **0.44** après homogénéisation : un tiers de la variance “climat-CO2” était portée par cet artefact technique.

## 1.9 9. Synthèse et regard critique

### 1.9.1 Résultats robustes

- **T2m global +0.78 K**, **CSDLF +7.84 W/m<sup>2</sup>** en 47 ans → signature GES confirmée.
- **10/21 variables “spurious”** : il faut systématiquement détendre avant analyse interannuelle.
- **15/21 X→CO2** Granger sig. à lag 6 mois → carbon cycle response dominante.
- **$R^2$  stepwise = 0.747** avec 12 prédictors sur le signal interannuel.

### 1.9.2 Limites identifiées

1. **Détendrage linéaire** alors que la trend CO2 est cubique → légère courbure résiduelle.
2. **Sauts CFSR/CFSv2** : l’homogénéisation par modèle additif corrige le **niveau** mais pas la **variance** (les CRE restent plus bruyants après 2011).
3. **Échelle globale uniquement** : les puits/sources tropicaux (Amazonie, Indonésie) sont noyés dans la moyenne — voir **phase 5** pour l’analyse régionale.

### 1.9.3 Pour aller plus loin

- **Phase 5** (04\_phase3\_climat\_05.ipynb) : distribution spatiale du réchauffement, cartes pixel-par-pixel, hotspots régionaux.